


Հետադարձ տարածման


Հետադարձ տարածման հիմքում ընկած է C գնի ֆունկցիայի՝ նեյրոնային ցանցերի w կշիռների (կամ b շեղումների) նկատմամբ մասնակի ածանցյալի $\partial C / \partial w$ արտահայտությունը: Այն ցույց է տալիս, թե ինչ «արագությամբ» է գինը փոփոխվում՝ կախված կշիռների և շեղումների փոփոխությունից: Այս արտահայտությունը փոքր-ինչ բարդ տեսք ունի, սակայն այն միաժամանակ շատ գեղեցիկ է, որի յուրաքանչյուր մասնիկն ունի բնական, ինտուիտիվ բացատրություն: Եվ, այսպիսով, հետադարձ տարածումը միայն արագագործ ալգորիթմ չէ, որը «ստիպված» ենք սովորել: Իրականում այն տալիս է խորը ներըմբռնում (insight) այն մասին, թե ինչպես է կշիռների և շեղումների փոփոխությունն ազդում ցանցի վարքագծի վրա: Այդ իսկ պատճառով այս ալգորիթմն արժանի է մանրամասն ուսուցման:

Մարզանք. նեյրոնային ցանցի էքսային արժեքների հաշվման արագագործ, մատրիցային մոտեցում

Նախ ցանցի կշիռներին տանք այնպիսի նշանակումներ, որոնք կօգտագործենք այդ կշիռներին հստակորեն հղվելու նպատակով: Նշանակենք w_{jk}^l -ով ցանցի $(l-1)$ -րդ շերտի k -րդ նեյրոնը l -րդ շերտի j -րդ նեյրոնին միացնող կապի կշիռը: Այսպիսով, օրինակ, ներքևի դիագրամում պատկերված կշիռը երկրորդ շերտի չորրորդ նեյրոնը միացնում է երրորդ շերտի երկրորդ նեյրոնի հետ:



Նմանատիպ նշանակումներ են օգտագործվում նաև ցանցի շեղումների և ակտիվացիաների համար: Եվ այսպես, l -րդ շերտի j -րդ նեյրոնին համապատասխանող շեղումը կնշանակենք b_j^l -ով: Ստորև ներկայացված դիագրամը ցույց է տալիս, թե ինչպես օգտագործել այս նշանակումները:



Ըստ այս նշանակումների, l -րդ շերտի j -րդ նեյրոնի a_j^l ակտիվացիան ($l-1$)-րդ շերտի նեյրոնների ակտիվացիաների հետ կապված է հետևյալ հավասարմամբ (1)

$$a_j^l = \sigma \left(\sum_k w_{jk}^l a_k^{l-1} + b_j^l \right)$$

որտեղ գումարն ըստ ($l-1$)-րդ շերտի k նեյրոնների է: Սահմանենք w^l կշիռների մատրիցը (*weight matrix*): w^l կշիռների մատրիցը կազմված է l -րդ շերտին կապվող նեյրոնների կշիռներից, այսինքն, j -րդ տողի k -րդ սյունակի էլեմենտը w_{jk}^l կշիռն է: Նույն ձևով, յուրաքանչյուր l շերտի համար սահմանենք b^l շեղման վեկտոր (*bias vector*): Ակնհայտ է, որ շեղման վեկտորի անդամները պարզապես b_j^l արժեքներն են՝ l -րդ շերտի նեյրոնների շեղումները: Եվ վերջապես, սահմանենք a^l ակտիվացիայի վեկտորը, որի անդամներն a_j^l ակտիվացիաներն են:

Հավասարումն զրենք մատրիցային տեսքով: Մեր նպատակն է, որպեսի σ -ն կարողանանք կիրառել v վեկտորի բոլոր էլեմենտների վրա: Ֆունկցիայի էլեմենտ-առ-էլեմենտ կիրառումը նշանակենք $\sigma(v)$ արտահայտությամբ: $\sigma(v)$ -ի տարրերը պարզապես $\sigma(v)_j = \sigma(v_j)$ էլեմենտներն են: Որպես օրինակ, դիտարկենք այն դեպքը, երբ ունենք $f(x) = x^2$ ֆունկցիան, ապա ֆունկցիայի վեկտորացված տեսքը կլինի՝

$$f\left(\begin{bmatrix} 2 \\ 3 \end{bmatrix}\right) = \begin{bmatrix} f(2) \\ f(3) \end{bmatrix} = \begin{bmatrix} 4 \\ 9 \end{bmatrix}$$

այսինքն վեկտորացված f -ն ուղղակի վեկտորի յուսքանչյուր անդամը քառակուսի է բարձրացնում:

Հաշվի առնելով այս բոլոր նշանակումները, (1) հավասարումը կարելի է գրել այսպիսի կոմպակտ վեկտորացված տեսքով. (2)

$$a^l = \sigma(w^l a^{l-1} + b^l)$$

Այս արտահայտությունը ընդհանուր առմամբ հնարավորություն է տալիս դիտարկել նախորդ շերտի ակտիվացիաների ազդեցությունը հաջորդ շերտի ակտիվացիաների վրա. ուղղակի կիրառում ենք կշիռների մատրիցը ակտիվացիաների վրա, այնուհետև ավելացնում ենք շեղման վեկտորը և վերջապես կիրառում σ ֆունկցիան :

Երկու ենթադրություններ գնային ֆունկցիայի վերաբերյալ


Հետադարձ տարածման նպատակն է հաշվել C գնային ֆունկցիայի $\partial C / \partial w$ և $\partial C / \partial b$ մասնական ածանցյալները w կշիռների և b շեղումների նկատմամբ: Կատարենք երկու ենթադրություններ հետադարձ տարածման համար: Սակայն, մինչ այդ դիտարկենք քառակուսային գնային ֆունկցիան, որը ունի հետևյալ տեսքը՝ (3)

$$C = \frac{1}{2n} \sum_x \|y(x) - a^L(x)\|^2$$

որտեղ n -ը մարզման օրինակների քանակն է, իսկ գումարն ըստ անհատական x մարզման օրինակների է, $y=y(x)$ համապատասխան ցանկալի ելքային արժեքն է և $a^L=a^L(x)$ ցանցի ելքային վեկտորն է x մուտքային վեկտորի դեպքում:

Այսպիսով, ի՞նչ ենթադրություններ կարող ենք կատարել C գնային ֆունկցիայի վերաբերյալ, որպեսզի հետադարձ տարածումը հնարավոր լինի կիրառել: Առաջին ենթադրությունն այն է, որ գնային ֆունկցիան կարելի է արտահայտել $C = \frac{1}{n} \sum_x C_x$ հավասարմամբ, որպես x մարզման օրինակներից կախված առանձին C_x գնային ֆունկցիաների հանրահաշվական միջին: Այս պնդումը ճիշտ է քառակուսային գնային ֆունկցիայի դեպքում, որտեղ $C_x = \frac{1}{2} \|y - a^L\|^2$ գնային ֆունկցիան է՝ կախված մեկ մարզման օրինակից: Այս ենթադրությունը ճիշտ կլինի նաև ժնացած այլ գնային ֆունկցիաների դեպքում:

Գնային ֆունկցիայի մասին երկրորդ ենթադրությունը այն է, որ այն կարելի է արտահայտել որպես ֆունկցիա կախված նեյրոնային ցանցերի ելքային արժեքներից:



Օրինակ, քառակուսային գնային ֆունկցիան բավարարում է այս պնդմանը, քանի որ քառակուսային գնային ֆունկցիան տրված x մուտքային վեկտորի համար կարելի է արտահայտել որպես (4)

$$C = \frac{1}{2} \|y - a^L\|^2 = \frac{1}{2} \sum_j (y_j - a_j^L)^2$$

որը ֆունկցիա է՝ կախված ելքային ակտիվացիաներից: C -ն կարող ենք դիտարկել որպես a^L ելքային վեկտորներից կախված ֆունկցիա, որտեղ y պարզապես պարամետր է, որը մասնակցում է ֆունկցիայի սահմանմանը:

Հաղամարի արտադրյալ՝ $s \odot t$


Հետադարձ տարածման ալգորիթմը հիմնված է որոշ գծային հանրահաշվի գործողությունների վրա՝ վեկտորների գումարում, վեկտորի բազմապատկում մատրիցով և այլն: Սակայն գործողություններից մեկն ավելի քիչ հաճախ է օգտագործվում քան մնացածները: Ենթադրենք, որ s և t միևնույն չափողականությամբ վեկտորներ են: Վեկտորների *էլեմենտ առ էլեմենտ* արտադրյալը նշանակենք $s \odot t$ արտահայտությամբ: Հետևաբար $s \odot t$ արտադրյալի տարրերը կլինեն $(s \odot t)_j = s_j t_j$ արժեքները: Դիտարկենք հետևյալ օրինակը.

$$\begin{bmatrix} 1 \\ 2 \end{bmatrix} \odot \begin{bmatrix} 3 \\ 4 \end{bmatrix} = \begin{bmatrix} 1 * 3 \\ 2 * 4 \end{bmatrix} = \begin{bmatrix} 3 \\ 8 \end{bmatrix}$$

Այս էլեմենտ առ էլեմենտ արտադրյալը այլ կերպ անվանում են *Հաղամարի արտադրյալ* կամ *Շուրի արտադրյալ*:

Հետադարձ տարածման հիմքում ընկած չորս հիմնական հավասարումները

Հետադարձ տարածումն այն մասին է, թե ինչպես է ցանցի գնային ֆունկցիան փոփոխվում՝ կախված կշիռների և շեղումների փոփոխություններից: Սա իր հերթին նշանակում է, որ պետք է հաշվել $\partial C / \partial w_{jk}^l$ և $\partial C / \partial b_j^l$ մասնակի ածանցյալները: Նախ ներմուծենք δ_j^l միջանկյալ մեծությունը, որը կկոչենք l -րդ շերտի j -րդ նեյրոնի *սխալանք (error)*:



1-րդ շերտի j-րդ նեյրոնի δ_j^l սխալանքը սահմանենք որպես (5)

$$\delta_j^l \equiv \frac{\partial C}{\partial z_j^l}.$$

Ինչպես մնացած դեպքերում, δ^l -ով կնշանակենք 1-րդ շերտի սխալանքների վեկտորը: Այնպիսի դասակարգման խնդիրներում, ինչպիսին է MNIST-ը, «սխալանք» տերմինը սովորաբար օգտագործվում է դասակարգման ձախողման գործակցի իմաստով: Օրինակ, երբ նեյրոնային ցանցը թվանշանների 96.0 տոկոսը ճիշտ է դասակարգում, ապա ձախողման գործակցիցը 4.0 տոկոս է:

Հարձակման պլանը: Հետադարձ տարածումը հիմնված է 4 ֆունդամենտալ հավասարումների վրա: Այդ հավասարումները միասին մեզ հնարավորություն են տալիս հաշվել δ^l սխալանքն ու գնային ֆունկցիայի գրադիենտը:

Ելքային շերտի սխալանքի δ^L հավասարումը: δ^L հավասարման էլեմենտներն ունեն հետևյալ տեսքը՝ (BP1)

$$\delta_j^L = \frac{\partial C}{\partial a_j^L} \sigma'(z_j^L).$$

Դիտարկենք այդ արտահայտությունը: Հավասարման աջ կողմի առաջին հատվածը՝ $\partial C / \partial a_j^L$ -ը պարզապես ցույց է տալիս, թե ինչ արագությամբ է գնային ֆունկցիան փոփոխվում՝ կախված j-րդ ելքային ակտիվացիայից: Աջակողմյան երկրորդ արտահայտությունը ցույց է տալիս σ ակտիվացիայի ֆունկցիայի փոփոխման արագությունը՝ կախված z_j^L -ից:

(BP1) հավասարումը սահմանում է δ^L վեկտորի անդամները: Հավասարումը չունի վեկտորական տեսք, ինչն անհրաժեշտ է հետադարձ տարածման համար, այնուամենայնիվ այն ճշգրիտ նկարագրում է ելքային շերտի սխալանքը: Այսպիսով, δ^L արտահայտությունը կարելի է գրել մատրիցային տեսքով հետևյալ կերպ՝ (BP1a)

$$\delta^L = \nabla_a C \odot \sigma'(z^L).$$

Որտեղ $\nabla_a C$ սահմանվում է որպես վեկտոր, որի անդամներն են $\partial C / \partial a_j^l$ մասնական ածանցյալները: $\nabla_a C$ -ն կարելի է ընկալել որպես C գնային ֆունկցիայի փոփոխման գործակիցը՝ կախված էլքային ակտիվացիաներից: Հեշտ է նկատել, որ (BP1a) և (BP1) հավասարումները համարժեք են:

δ^l սխալանաքի արտահայտումն ըստ հաջորդ շերտի δ^{l+1} սխալանքի: Դիտարկենք հետևյալ հավասարումը. (BP2)

$$\delta^l = ((w^{l+1})^T \delta^{l+1}) \odot \sigma'(z^l),$$

որտեղ $(w^{l+1})^T$ կշիռների w^{l+1} տրանսպոնացված մատրիցն է՝ $(l+1)$ -րդ շերտի համար :

Միավորելով (BP2) և (BP1) հավասարումները, կարող ենք δ^l սխալանքը հաշվել ցանցի կամայական շերտում: Կսկսենք δ^L -ի հաշվումից՝ օգտագործելով (BP1) հավասարումը, այնուհետև կօգտագործենք (BP2) հավասարումը, որպեսզի հաշվենք δ^{L-1} սխալանքը, այնուհետև կկրկնենք (BP2) հավասարման կիրառումը, որպեսզի հաշվենք δ^{L-1} և այդպես շարունակ մինչև ցանցի «սկիզբը»

Գնային ֆունկցիայի փոփոխման գործակցի հավասարումը՝ կախված ցանցի շեղումներից: Դիտարկենք հետևյալ հավասարումը. (BP3)

$$\frac{\partial C}{\partial b_j^l} = \delta_j^l.$$

Այն է, δ_j^l սխալանքը ճիշտ նույնն է, ինչ $\partial C / \partial b_j^l$ փոփոխման գործակիցը: Քանի որ (BP1) և (BP2) արդեն ցույց են տվել, թե ինչպես կարելի է հաշվել δ_j^l սխալանքը: Կարող ենք (BP3) հավասարումն գրել կարճ որպես

$$\frac{\partial C}{\partial b} = \delta,$$

որտեղ δ հաշվարկում ենք նույն նեյրոնի համար, ինչի համար դիտարկում էինք b շեղումը:

Գնային ֆունկցիայի փոփոխման գործակցի հավասարումը՝ կախված ցանցի կշիռներից: Դիտարկենք հետևյալ հավասարումը՝ (BP4)

$$\frac{\partial C}{\partial w_{jk}^l} = a_k^{l-1} \delta_j^l.$$

Այն ցույց է տալիս, թե ինչպես կարելի է հաշվել $\partial C / \partial w_{jk}^l$ մասնական ածանցյալներն ըստ δ^l և a^{l-1} մեծությունների: Հավասարումը կարելի է արտահայտել ավելի կարճ տեսքով հետևյալ կերպ.

$$\frac{\partial C}{\partial w} = a_{in} \delta_{out},$$

որտեղ a_{in} մեծությունը w կշիռների հետ միասին մուտք հանդիսացող նեյրոնի ակտիվացիան է և δ_{out} -ն նեյրոնի արդյունքի ելքային սխալանքն է w կշիռների դեպքում: Երբ $a_{in} \approx 0$, ապա $\partial C / \partial w$ գրադիենտի արժեքը նույնպես կձգտի փոքր արժեքների: Այդ դեպքում կասենք, որ կշիռը *դանդաղ է սովորում*, ինչը նշանակում է, որ այն շատ չի փոփոխվում գրադիենտային վայրէջքի ժամանակ: Այլ կերպ ասած (BP4) հավասարման հետևանքներից մեկն այն է, որ թույլ ակտիվացիայով (low-activation) նեյրոններից դուրս եկող կշիռները դանդաղ են սովորում:

(BP1) - (BP4) . հավասարումներից կարելի է անել նաև այլ հետևություններ: Դիտարկենք $\sigma'(z_j^l)$ արտահայտությունը (BP1) . հավասարման մեջ: Վերջին շերտի կշիռները դանդաղ կսովորեն, եթե ելքային նեյրոնն ունի թույլ ակտիվացիա (≈ 0) կամ ուժեղ ակտիվացիա (≈ 1): Այս դեպքում ասում են, որ ելքային նեյրոնը *հագեցած (saturated)* է և արդյունքում կշիռը դադարել է սովորել (կամ սովորում է շատ դանդաղ): Նմանատիպ պնդումներ կարելի է անել նաև ելքային նեյրոնի շեղումների մասին:

Նմանատիպ հետևություններ կարող ենք կատարել նաև միջանկյալ շերտերի դեպքում: Դիտարկենք $\sigma'(z^l)$ արտահայտությունը (BP2) . հավասարման մեջ: Պարզ է, որ δ_j^l ավելի հավանական է, որ փոքր լինի, եթե նեյրոնը մոտ է հագեցմանը: Եվ սա, իր հերթին նշանակում է, որ յուրաքանչյուր կշիռների մուտք հագեցած նեյրոնին կսովորի դանդաղորեն:

Այսպիսով, մենք սովորեցինք, որ կշիռը կսովորի դանդաղորեն, եթե մուտքային ներքոնը թույլ ակտիվացիայով է կամ երբ ելքային ներքոնը հագեցած է, այն է ունի ուժեղ կամ թույլ ակտիվացիա:

Հետադարձ տարածման ալգորիթմը

Հետադարձ տարածման հավասարումները ցույց են տալիս, թե ինչպես կարելի է հաշվել գնային ֆունկցիայի գրադիենտը: Արտահայտենք դա ալգորիթմի տեսքով.

1. **Մուտք** x : a^1 ակտիվացիայի շերտը սկզբնավորենք մուտքային շերտով:
2. **Առաջադիմում (Feedforward)**: Յուրաքանչյուր $l=2,3,\dots,L$ շերտերի համար հաշվել $z^l = w^l a^{l-1} + b^l$ and $a^l = \sigma(z^l)$.
3. **Ելքային սխալանք** δ^L : Հաշվել $\delta^L = \nabla_a C \odot \sigma'(z^L)$ վեկտորը:
4. **Սխալանքի հետադարձ տարածումը (Backpropagate)**: Յուրաքանչյուր $l=L-1, L-2, \dots, 2$ շերտի համար հաշվել $\delta^l = ((w^{l+1})^T \delta^{l+1}) \odot \sigma'(z^l)$.
5. **Ելք**: Գնային ֆունկցիայի գրադիենտը տրվում է $\frac{\partial C}{\partial w_{jk}^l} = a_k^{l-1} \delta_j^l$ and $\frac{\partial C}{\partial b_j^l} = \delta_j^l$ հավասարումներով:

Դիտարկելով ալգորիթմը, կարելի է տեսնել, թե ինչու է այն կոչվում *հետադարձ* տարածում: Սխալանքի վեկտորները հետադարձ հաշվարկվում են՝ սկսելով վերջին շերտից: Հետադարձ գործողությունը հետևանք է այն բանի, որ գնային ֆունկցիան կախված է ցանցի ելքային արժեքներից: Որպեսզի հասկանանք գնի փոփոխությունը կախված կշիռներից և շեղումներից, պետք է կրկնողաբար կիրառենք բարդ ֆունկցիայի դիֆերենցման կանոնը, հետ վերադառնալով շերտ առ շերտ, որպեսզի ստանանք համապատասխան արտահայտությունները:

Հետադարձ տարածման ալգորիթմը հաշվում է գնային ֆունկցիայի գրադիենտը տրված $C=C_x$ մարզման օրինակի համար: Հաճախ հետադարձ տարածումը միավորվում է այնպիսի ուսուցման ալգորիթմի հետ, ինչպիսին է ստոկաստիկ

գրադիենտային վայրէջքը, որտեղ գրադիենտը հաշվարկվում է բազմաթիվ օրինակների հիման վրա: Տրված m մարզման օրինակների մինի-փաթեթի համար, հետևյալ ալգորիթմը կիրառում է գրադիենտային վայրէջքի ուսուցման քայլը՝ հիմնված այդ մինի-փաթեթի վրա:

1. **Մուտքագրեք մարզման օրինակների բազմությունը:**

2. **Յուրաքանչյուր x մարզման օրինակի համար.** Սկզբնավորենք համապատասխան $a^{x,1}$ մուտքային ակտիվացիան և կատարենք հետևյալ քայլերը.

- **Առաջ քերում (Feedforward):** Յուրաքանչյուր $l=2,3,\dots,L$ շերտի համար հաշվենք $z^{x,l} = w^l a^{x,l-1} + b^l$ և $a^{x,l} = \sigma(z^{x,l})$ արտահայտությունների արժեքները:
- **Ելքային սխալանքը՝ $\delta^{x,L}$:** Վեկտորի հաշվումը. $\delta^{x,L} = \nabla_a C_x \odot \sigma'(z^{x,L})$.
- **Սխալանքի հետադարձ տարածումը:** Յուրաքանչյուր $l=L-1, L-2, \dots, 2$ հաշվել $\delta^{x,l} = ((w^{l+1})^T \delta^{x,l+1}) \odot \sigma'(z^{x,l})$.

3. **Գրադիենտային վայրէջք:** Յուրաքանչյուր $l = L, L-1, \dots, 2$ թարմացնել կշիռները ըստ հետևյալ կանոնի՝ $w^l \rightarrow w^l - \frac{\eta}{m} \sum_x \delta^{x,l} (a^{l-1})^T$, և շեղումներն ըստ $b^l \rightarrow b^l - \frac{\eta}{m} \sum_x \delta^{x,l}$ կանոնի.

Ի՞նչ իմաստով է հետադարձ տարածումն արագագործ ալգորիթմ

Ի՞նչ իմաստով է հետադարձ տարածումն արագագործ ալգորիթմ: Այս հարցին պատասխանելու համար դիտարկենք գրադիենտի հաշվման այլ մոտեցում: Դիտարկենք գնի ֆունկցիան կախված միայն կշիռներից $C=C(w)$ (շեղումներին դեռ կվերադառնանք): Այնուհետև համարակալում ենք կշիռները՝ w_1, w_2, \dots և հաշվում $\partial C / \partial w_j$ մասնական ածանցյալները տրված w_j կշռի համար: Կարելի է օգտագործել հետևյալ մոտարկումը՝ (6)

$$\frac{\partial C}{\partial w_j} \approx \frac{C(w + \epsilon e_j) - C(w)}{\epsilon},$$

որտեղ $\epsilon > 0$ փոքր դրական թիվ է և e_j միավոր վեկտորն է j -րդ ուղղության վրա: Այսպիսով, կարող ենք գնահատել $\partial C / \partial w_j$ մասնական ածանցյալները հաշվելով C գինը երկու տարբեր (իրար մոտ) w_j արժեքների համար և կիրառել (6) հավասարումը: Նույն ձևով կարող ենք հաշվել նաև $\partial C / \partial b$ շեղումների դեպքում:

Այս մոտեցումը խոստումնալից է թվում: Այն հիմնված է համեմատաբար պարզ կոնցեպտների վրա և բավականին դյուրին է իրականացնելը:

Դժբախտաբար, մինչդեռ այս մոտեցումը խոստումնալից է թվում, իրականացումը բավականին դանդաղագործ է: Որպեսզի հաշվենք գրադիենտը, պետք է գնային ֆունկցիայի արժեքը մի քանի անգամներ հաշվենք, ինչի հետևանքով մի քանի անգամ պետք է առաջ շարժվենք ցանցով: Դա չի ներառում $C(w)$ արժեքի հաշվումը:


Հետադարձ տարածման առավելությունը կայանում է նրանում, որ այն միաժամանակ հաշվում է *բոլոր* $\partial C / \partial w_j$ մասնական ածանցյալները՝ օգտագործելով միայն մեկ առաջ տարածում և մեկ հետադարձ տարածում ցանցով: Հետադարձ առաջխաղացման հաշվարկային արագությունը (computational cost) համարյա նույնն է, ինչ առաջ տարածման: Հետևաբար հետադարձ տարածման ընդհանուր հաշվարկային գինը նույնն է, ինչ ցանցում երկու առաջաբեր գործողությունն կատարելիս: Համեմատենք դա միլիոնից ավել առաջաբեր գործողությունների հետ, որ անհրաժեշտ կլինեք, եթե մենք որդեգրեինք ներքևում նշված հավասարման հիման վրա կառուցված մեթոդը: (6) Եվ այսպիսով, չնայած նրան, որ հետադարձ տարածումն ունի բավականին բարդ տեսք, քան (6) մոտեցումը, այն անհամեմատ ավելի արագագործ է:

Հետադարձ տարածում. ամբողջական պատկերը


Այսպիսով, գոյություն ունեն առեղծվածներ կապված հետադարձ տարածման հետ: Առաջին. ի՞նչ է ըստ էության ալգորիթին անում: Բնարկե, մենք ցույց տվեցինք, որ սխալանքը ելքից տարածվում է դեպի ետ, սակայն արդյո՞ք կարող ենք ավելի խորանալ և ձեռք բերել ինտուցիա այն մասին, թե ինչ է տեղի ունենում երբ մենք

այսքան մատրիցներ և վեկտորներ իրար ենք բազմապատկում: Երկրորդ առեղծվածն այն է, թե ինչպե՞ս կարելի է հայտնագործել հետադարձ տարածման ալգորիթմը: Իհարկե կարելի է հետևել և հասկանալ ալգորիթմի քայլերն ու ապացույցը, սակայն արդյո՞ք խնդիրը հասկանում ենք այնքան խորությամբ, որ կարող էինք ալգորիթմն ինքնուրույն հայտնագործել: Արդյոք կա տրամաբանական շղթա, որին հետևելով կարող էինք հանգել հետադարձ տարածման ալգորիթմին: Այս հատվածում կդիտարկենք այդ երկու առեղծվածները:


Որպեսզի մեր ինտուցիան այս ալգորիթմի վերաբերյալ բարելավենք, ենթադրենք, որ ցանցի որևիցե w_{jk}^l կշռի նկատմամբ կիրառել ենք Δw_{jk}^l փոփոխությունը.




Այս փոփոխությունը կհանգեցնի համապատասխան փոփոխությունն այդ նեյրոնին համապատասխանող ելքային ակտիվացիայում:



Որն իր հերթին կհանգեցնի հաջորդ շերտի *բոլոր* ակտիվացիաների փոփոխության:



Այդ փոփոխություններն իրենց հերթին կառաջացնեն փոփոխություններ հաջորդ շերտում, այնուհետև հաջորդ և այդպես շարունակ մինչև վերջնական շերտը հանգեցնելով փոփոխության գնային ֆունկցիայում:



Գնային ֆունկցիայի ΔC փոփոխությունը կշռի Δw_{jk}^l փոփոխության հետ կապված է հետևյալ հավասարմամբ. (7)


$$\Delta C \approx \frac{\partial C}{\partial w_{jk}^l} \Delta w_{jk}^l.$$

Սա ցույց է տալիս, որ $\frac{\partial C}{\partial w_{jk}^l}$ հաշվարկելու հնարավոր տարբերակներից մեկն այն է, որ հետևենք, թե ինչպես է w_{jk}^l տարծվում և փոքրիկ փոփոխություն առաջացնում C գնային ֆունկցիայում: Եթե դա ուշադիր կերպով իրականացնենք, հաշվելով բոլոր միջանկյալ արժեքները, ապա կարող ենք հաշվել $\frac{\partial C}{\partial w_{jk}^l}$ արժեքը...

Փորձենք դա իրականացնել: Δw_{jk}^l փոփոխությունն առաջացնում է Δa_j^l փոքրիկ փոփոխությունը l -րդ շերտի j -րդ ակտիվացիայում: Այդ փոփոխությունը կարելի է նկարագրել հետևյալ կերպ: (8)

$$\Delta a_j^l \approx \frac{\partial a_j^l}{\partial w_{jk}^l} \Delta w_{jk}^l.$$

Փոփոխությունը Δa_j^l ակտիվացիայում կառաջացնի փոփոխություններ հաջորդ *բոլոր* շերտերի ակտիվացիաներում, օրինակ, $(l+1)$ -րդ շերտում: Դիտարկենք, թե ինչպես է փոփոխվում այդ ակտիվացիաներից որևիցե մեկը, օրինակ՝ a_q^{l+1} :



Ըստ էության, հետևյալ փոփոխությունը տեղի կունենա. (9)

$$\Delta a_q^{l+1} \approx \frac{\partial a_q^{l+1}}{\partial a_j^l} \Delta a_j^l.$$

Կատարելով փոխարինում (8), հավասարումով, կստանանք. (10)

$$\Delta a_q^{l+1} \approx \frac{\partial a_q^{l+1}}{\partial a_j^l} \frac{\partial a_j^l}{\partial w_{jk}^l} \Delta w_{jk}^l.$$

Իհարկե, Δa_q^{l+1} ակտիվացիայի փոփոխությունն իր հերթին կհանգեցնի փոփոխությունների հաջորդ շերտերում: Կարող ենք պատկերացնել ցանցում այդպիսի փոփոխությունների ուղի՝ w_{jk}^l -ից դեպի C գնային ֆունկցիա, որտեղ յուրաքանչյուր փոփոխություն ակտիվացիայում հանգեցնում է հաջորդ շերտի ակտիվացիաների փոփոխության, վերջապես շղթայաբար հասնելով գնային ֆունկցիայի փոփոխության ելքում: Եթե այդ ուղին անցնում է a_l^l , a_q^{l+1} , ..., a_n^{l-1} , a_m^l ակտիվացիաներով, ապա գնային ֆունկցիայի փոփոխությունը կարելի է նկարագրել հետևյալ կերպ. (11)

$$\Delta C \approx \frac{\partial C}{\partial a_m^L} \frac{\partial a_m^L}{\partial a_n^{L-1}} \frac{\partial a_n^{L-1}}{\partial a_p^{L-2}} \cdots \frac{\partial a_q^{L+1}}{\partial a_j^L} \frac{\partial a_j^L}{\partial w_{jk}^L} \Delta w_{jk}^L,$$

որտեղ յուրաքանչյուր փոփոխված նեյրոնի համար կիրառել ենք $\partial a/\partial a$ տիպի փոփոխությունն նկարագրող արտահայտությունը՝ վերջում կիրառելով $\partial C/\partial a_m^L$ գնային ֆունկցիայի փոփոխությունը կախված ելքային նեյրոնից: Այսպիսով, C-ի փոփոխությունը կարելի է ներկայացնել այս կերպ՝ հիմնված ակտիվացիաների շղթայական փոփոխությունների վրա : C գնային ֆունկցիայի ամբողջական փոփոխությունը հաշվելու համար պետք է գումարել փոփոխությունները տրված կշռից դեպի գնային ֆունկցիա բոլոր հնարավոր ուղիներով: Օրինակ. (12)


$$\Delta C \approx \sum_{mnp \dots q} \frac{\partial C}{\partial a_m^L} \frac{\partial a_m^L}{\partial a_n^{L-1}} \frac{\partial a_n^{L-1}}{\partial a_p^{L-2}} \cdots \frac{\partial a_q^{L+1}}{\partial a_j^L} \frac{\partial a_j^L}{\partial w_{jk}^L} \Delta w_{jk}^L,$$

որտեղ գումարն ըստ բոլոր հնարավոր միջանկյալ նեյրոնների է: Համեմատելով (7) հավասարման հետ, կտեսնենք, որ (13)

$$\frac{\partial C}{\partial w_{jk}^L} = \sum_{mnp \dots q} \frac{\partial C}{\partial a_m^L} \frac{\partial a_m^L}{\partial a_n^{L-1}} \frac{\partial a_n^{L-1}}{\partial a_p^{L-2}} \cdots \frac{\partial a_q^{L+1}}{\partial a_j^L} \frac{\partial a_j^L}{\partial w_{jk}^L}.$$

Այժմ (13) հավասարումը բարդ տեսք ունի: Սակայն այն ունի պարզ ինտուիտիվ մեկնաբանություն: Մենք հաշվում ենք C փոփոխության գործակիցը կախված ցանցի կշռից: Այնուամենայնիվ, այն ունի գեղեցիկ ինտուիտիվ մեկնաբանություն: Մենք հաշվարկում ենք C-ի փոփոխության արագությունը ցանցում որոշակի քաշի նկատմամբ: Հավասարումը մեզ ասում է, որ ցանցում երկու նեյրոնների միջև յուրաքանչյուր եզր կապված է արագության գործակցի հետ, որը մեկ նեյրոնի ակտիվացման մասնակի ածանցյալն է մյուս նեյրոնի ակտիվացման նկատմամբ: Առաջին քաշից մինչև առաջին նեյրոնը ընկած եզրն ունի արագության գործակից $\partial a_j^L/\partial w_{jk}^L$: Ճանապարհի արագության գործակիցը պարզապես ճանապարհի երկայնքով արագության գործոնների արտադրյալն է: Եվ փոփոխության ընդհանուր

արագությունը $\partial C / \partial w_{jk}^l$ պարզապես բոլոր ուղիների արագության գործոնների գումարն է սկզբնական քաշից մինչև վերջնական արժեքը: Այս ընթացակարգը պատկերագրված է այստեղ՝ մեկ ճանապարհի համար:



Կարող ենք ստանալ հստակ արտահայտություններ (է3) հավասարման բոլոր առանձին մասնակի ածանցյալների համար: Դա հեշտ է անել մի փոքր հաշվարկով: Դա անելուց հետո կարող ենք փորձել պարզել, թե ինչպես գրել ինդեքսների վրա բոլոր գումարները որպես մատրիցային բազմապատկումներ: Սա պահանջում է որոշակի համառություն: Այս ամենը անելուց և այնուհետև հնարավորինս պարզեցնելուց հետո, հայտնաբերում ենք, որ ի վերջո ստանում ենք հենց հետադարձ տարածման ալգորիթմը: Եվ այսպես, կարող ենք մտածել հետադարձ տարածման ալգորիթմի մասին որպես այս բոլոր ուղիների համար գումարի արագության գործակցի վրա հաշվարկման միջոց: Կամ, մի փոքր այլ կերպ ասած, հետադարձ տարածման ալգորիթմը խելացի միջոց է կշիռների (և շեղումների) փոքր տատանումները հետևելու համար, երբ դրանք տարածվում են ցանցով, հասնում ելքային արժեքին և այնուհետև ազդում արժեքի վրա: